목진희

AI·자동화 엔지니어 · 설계부터 배포·운영까지

경력기술서

jinheemok815@gmail.com
jin-tonix.github.io · GitHub
서울 강남구

법학을 전공했고 어린이집 운영실장과 영어 강사로 일했습니다. 2024년 하이미디어아카데미에서 개발을 배웠고 We:Review 인턴 때 OCR과 LLM으로 영수증 검수를 자동화했습니다. 지금은 현업의 반복 업무를 AI 에이전트와 자동화로 옮기는 일을 합니다. 시스템은 후보와 제안까지만 내고 확정은 직원이 하게 설계합니다. 코드는 AI 코딩 도구(Claude Code)에 많이 맡기고, 만들 범위와 운영에 쓸 범위를 정하고 결과를 확인하는 일은 제가 합니다.

스타일셀러 (STYLESELLER) · PL (AI·자동화) · 2025.11 ~ 재직 중

직원이 손으로 반복하던 거래처 기록 정리, 응대, 계산 업무를 AI 에이전트와 사내 업무툴로 옮기고 배포와 운영까지 맡았습니다.

1. 현황판 · 운영 원장 2026.10.19 ~ 10.23 구현, 운영 중

역할: 원장 스키마와 상대 연결 규칙 설계, 인입 API·메일 수집기·화면 탭 6개 구현, DB 시험과 운영 화면 검증.

만든 것: 카톡방, 주문 메일함, 슬랙, 메일 첨부 엑셀 주문서를 하루 단위로 요약해 상대별 달력에 날짜순으로 올립니다. 같은 기록이 여러 번 와도 원장에는 한 번만 남습니다. 기록과 상대는 LLM 없이 정해진 규칙 순서(스레드, 사업자번호, 카톡방, 이메일 등)로 잇고 키가 엇갈리면 미분류로 두고 직원이 정합니다.

결과: 상대 352곳(브랜드 147, 벤더사 135, 셀러 70)의 거래 단계를 한 화면에 표시(2026-10-24). 평일 하루 100~200건 안팎의 기록 수집, 자동으로 잇지 못한 기록은 상대확인 화면에서 직원이 연결(대기 수백 건, 10-24). 매일 18:05에 상대 최대 300곳의 요약을 다시 쓰고, 하루 비용이 2,000원을 넘으면 그날 배치 중단.

기술: React·Tailwind·Vitest, Python 3.12·Pydantic v2, Postgres RLS, Gemini Flash 계열(LiteLLM 경유)

2. 콘텐츠 오토파일럿 2026.10.03 ~ 현재

역할: 단계 상태기계와 게시 기본값 설계. 오케스트레이터, 게시 관문과 DB 슬롯, QA 관문 구현. 운영 canary와 재시작 시나리오 테스트.

만든 것: 실무자가 업무툴에서 릴스를 요청하면 대본을 쓰고 9:16 MP4로 렌더한 뒤 미리보기 승인을 받습니다. 단계 진행은 LLM 없는 상태기계가 맡습니다. 기본값은 게시 수동, 반복 자동화 dry-run, 유료 생성 꺼짐이고, 'AI 생성 콘텐츠' 표시는 자동으로 붙습니다.

결과: 운영 canary로 1080×1920 MP4를 Drive에 저장하는 데까지 검증(2026-10). 이 신규 제작 경로는 기술은 완성됐지만 프롬프트 같은 세부는 아직 다듬는 중이라 SNS 실게시는 없고, 기존 영상은 캡션·해시태그만 계정별로 바꿔 여러 계정에 동시 게시하는 별도 경로로 이미 실제 운영 중입니다. 계정당 하루 게시 1건을 DB 인덱스로 강제. 서비스 3개의 테스트 파일 617개.

기술: 콘텐츠 오케스트레이터, Hermes, Gemini Flash 계열(LiteLLM 경유), 영상 렌더러, HyperFrames, ffprobe, Google Drive, Supabase(PostgreSQL)

3. 벤더 CS 에이전트 2026.06 ~ 현재

역할: 수집 경로, 거래처 게이트, 근거 대조 규칙 설계. 서버 에이전트, kakaocli 포크의 발송·도착 확인, 윈도우 수집기 구현. 사고 대응과 운영.

만든 것: 직원 PC에서 카카오톡 대화를 모아 서버로 올리고, 답도 직원 맥에서 보냅니다. 방 이름을 응대 대상 명단과 대조해 거래처를 못 찾으면 답하지 않습니다. 태그된 질문에는 거래처 기록과 지식 허브를 검색해 답하고, 초안의 금액·%·브랜드를 근거와 코드로 대조해 어긋나면 다시 검색해 고쳐 씁니다.

결과: 메시지 1건이 51번 들어오던 재전송 문제를 15초 중복 제거로 정리. 발송 147건 중 31건(21%)이 실패하던 macOS 접근성 멈춤을 3초 제한 시간과 도착 확인(카톡 DB 개수 대조)으로 수정. 벤더 에이전트 커밋 600개, 테스트 파일 107개(2026-09-23).

기술: kakaocli 포크(Swift), 윈도우 읽기 전용 수집기(Python), Python 3.12, LightRAG, Gemini Flash 계열(LiteLLM 경유), 구글 시트·드라이브

4. 에이전트 플랫폼 · Spark 2026.05 ~ 현재

역할: 작업지시서, 위임 가드, 도구 게이트 구조 설계. 공용 도구·스킬 상자 연결, 승인 1회, LiteLLM 비용 상한, Jev 연결 구현. 평가 세트 작성과 측정 오류 정정, VM 배포.

만든 것: Paperclip을 포크한 사내 에이전트 플랫폼입니다. 직원은 Spark로 업무 DB 4개에 읽기 전용으로 질문하고 일은 CEO 에이전트에게 맡깁니다. 위임 깊이 2, 지시서당 위임 5회 제한, 도구 승인은 프롬프트가 아니라 서버와 DB에서 강제합니다. BM25가 공용 스킬 115개 중 후보를 추리면 Jev가 게이트·적합도로 다시 거르고, Gemini가 그 중 1개를 최종 선택합니다.

결과: 10-24 기준 공용 스킬 109개에서 BM25로 추린 후보 안에 정답이 든 비율인 재현율은 정답 있는 69문항(2026-10-24)에서 1순위 85.5%, 상위 3개 91.3%였습니다. 승인은 한 번만 실행됩니다(동시 요청 10개에 실행 1개, 테스트로 확인). 유료 호출은 하루 3만원 상한이고 넘으면 재시도하지 않게 403으로 응답합니다. 후속(2026-10-25~): Hermes 에이전트의 Jev 라우터에 LLM 제안자를 넣어 새 질문 132건(이후 재사용)에서 정답률 90.15%(119건, 스킬 115개)를 냈습니다. 시험 폴더에만 있던 가짜 스킬과 정답표 오류를 찾아 수치를 정정하고 다시 쟀습니다. 앞의 85.5·91.3%는 후보 재현율이라 이 값과 비교하지 않습니다. BM25가 추리고 Jev가 다시 거르는 방식도 같은 132건에서 90.15%(119건)로 Gemini 단독과 비슷했고, Gemini가 읽는 양이 줄어 비용은 약 1/10로 추정됩니다. 이 방식을 전면 적용해 지금 Hermes 에이전트가 스킬을 고를 때 씁니다.

기술: Paperclip 포크(Express 5, Drizzle, PostgreSQL), MCP SDK, Hermes, Python 3.12·FastAPI, LiteLLM, Redis, Langfuse, Gemini Flash 계열(LiteLLM 경유)

5. LightRAG 지식 허브 · 메일 에이전트 2026.03.31 ~ 현재

역할: 워크스페이스 등록부, 검색 계획과 근거 판정 단계, 초안 검증 순서 설계. 메일 에이전트 서버, 검사기, 보낸 메일 학습 커서 구현. 배포와 사고 복구.

만든 것: 벤더 CS, 인플루언서 CS, Spark, 판매 파트너사 매칭이 함께 쓰는 지식 허브입니다. 공용 메일함 문의에는 근거를 붙인 답장 초안을 담당자 Gmail 초안함에 넣고, 발송은 직원이 합니다. 초안의 주장 최대 6개를 근거와 대조해 근거가 없으면 다시 쓰고, 다시 써도 근거 없는 주장이 남으면 초안을 버립니다.

결과: 에이전트 4개가 워크스페이스 13개를 공유, 이름이 어긋나면 서버가 뜨지 않게 고정. 보낸 메일 1,943건 중 48건이 학습에서 빠지던 문제를 커서 저장 방식 변경으로 수정.

기술: Python 3.12·FastAPI·Pydantic v2, LightRAG(Postgres/pgvector + Neo4j), FlashRank, Gemini Flash 계열(LiteLLM 경유), Gmail, pytest

6. 사내 업무툴 · 가격·매칭·맞춤카톡 2026.03 말 ~ 현재

역할: 가격 계산 구조, 매칭 후보 규칙, 발송 승인 기준 설계. 가격 코드, 카탈로그 추출, 매칭, 발송 자동화, 직원 PC 워커 구현과 운영. 셀러 추천 로직은 동료 CRM 담당.

만든 것: 구글 시트 가격 수식을 올림 단위까지 코드로 옮겼습니다. LLM은 고칠 입력값 JSON만 내고 금액은 코드가 다시 계산합니다. 카탈로그(PDF·이미지·엑셀·URL)에서 LLM이 상품 후보를 뽑고 직원이 확인한 것만 등록합니다. 맞춤카톡은 CRM에서 받은 대상에게 발송하고, 500명 이상이면 승인 대기로 넘깁니다.

결과: 가격 계산 시험 43케이스, 일부는 실제 상품의 시트 값과 칸별 대조. 맞춤카톡 하루 261명 발송(2026-09-22). 셀러찾기 워커는 직원 PC 11대 중 9대 운영, 공유 키를 PC별 키로 교체(2026-09).

기술: React·Vitest, Postgres+PostgREST, Gemini Flash 계열(LiteLLM 경유), 지식 허브 RAG 검색, kakaocli

7. 직원 PC 배포 · 운영 2026.02 ~ 현재

역할: 설치·인증·갱신 구조와 서버 기준일 설계. 설치기, 워커, 윈도우 수집기, kakaocli 포크 수정 구현. 배포, 사고 대응, 감시 크론 운영.

만든 것: 카톡과 인스타 작업을 직원 맥과 윈도우 PC에서 실행합니다. 설치는 한 줄 명령, 인증은 1회용 토큰으로 받는 기기별 키, 갱신은 PC마다 시각을 다르게 잡은 자동 주기입니다. 서버는 커밋한 이미지로만 배포하고 이미지가 없으면 배포를 멈춥니다.

결과: 직원 PC 11대(맥·윈도우) 한 줄 설치 배포(2026-09-16 등록 기준). 2026-08-20 클라우드 DB 사용 한도 초과로 업무툴 API가 모두 멈췄을 때 VM에 같은 API(PostgREST)를 세워 당일 복구, 앱의 DB 호출 코드 100여 곳은 그대로 유지. DB 4개 자체 호스팅 이전(2026-08-06 ~ 08-25).

기술: macOS bash·Windows PowerShell 설치기, launchd·작업 스케줄러, Node 워커, Python 수집기, VM Postgres+PostgREST+nginx, SSE 푸시, Docker, Slack 감시 크론

위리드 (WE:REVIEW) · AI 개발 인턴 · 2025.08 ~ 2025.10

영수증 이미지에서 상품과 가격을 JSON으로 뽑는 검수 파이프라인 구현. PaddleOCR 타일 분할, DBSCAN 줄 복원, 오픈 LLM(Qwen 계열) few-shot, FastAPI 서비스화. 검수 정확도 70%에서 95%로 향상, 검수 시간 85% 단축(직접 측정).

이전 경력

영어 강사 · 정상어학원(2018.08 ~ 2020.09), 파츠앤팬스(2021.03 ~ 2022.05), 몬테키즈어학원(2022.06 ~ 2024.02): 수업 설계, 교안 제작, 학부모 상담.

전원어린이집·방과후학교 · 운영실장(2015.03 ~ 2018.02): 교사 채용, 커리큘럼·행사 기획, 원장 대행 운영.